

## 基于深度区域提取网络对中尺度涡的检测算法

陈扬<sup>1</sup>, 杨琛<sup>1</sup>, 刘博文<sup>1</sup>

<sup>1</sup> 中国海洋大学 青岛

(chenyang8484@stu.ouc.edu.cn)

## Detection algorithm of mesoscale eddy based on deep region extraction network

Chen Yang<sup>1</sup>, Yang Chen<sup>1</sup>, Liu Bowen<sup>1</sup>

<sup>1</sup> Ocean University of China, Qingdao

**Abstract** Mesoscale eddy is an important research topic in the field of marine science. Among them, the detection of mesoscale vortices is an important research direction in mesoscale eddy research and has very important scientific significance. In recent years, deep neural networks in the field of artificial intelligence have developed rapidly, and they are widely used to solve many practical problems in computer vision. In this paper, the object detection algorithm in deep learning is applied to mesoscale eddy detection. Compared with the traditional mesoscale eddy detection method, only the position and size of the mesoscale eddy can be detected, which can better utilize multimodal information for positioning. Classification and instance segmentation. Based on the Mask-RCNN algorithm, this paper proposes an object detection algorithm combining multi-modal satellite remote sensing image data to identify, classify and segment mesoscale vortices in the ocean. The experimental results show that our method can effectively extract the features of mesoscale eddies and accurately detect and locate them. At the same time, our method obtains higher accuracy.

**Key words:** Mesoscale eddy, Object detection, Deep learning, Multimodal data fusion

**摘要** 中尺度涡是海洋科学领域一个重要的研究课题。其中,中尺度涡的检测是中尺度涡研究中重要的研究方向,有着非常重要的科学意义。近年以来,人工智能领域中的深度神经网络高速发展,其被广泛应用于解决计算机视觉中许多实际问题。本文将深度学习中的目标检测算法应用于中尺度涡检测,相比较于传统的中尺度涡检测方法只能检测中尺度涡的位置和大小,其能更好地利用多模态信息进行定位、分类和实例分割。本文基于 Mask-RCNN 算法,提出一种结合多模态卫星遥感图像数据的目标检测算法,对海洋中的中尺度涡进行识别、分类和分割。实验结果表明我们的方法能够有效提取中尺度涡的特征,并对其进行精确检测和定位,同时我们的方法获得了较高准确率。

**关键词:** 中尺度涡,目标检测算法,深度学习,多模态数据融合

中图法分类号 TP391

在海洋领域,中尺度涡是指在海洋中半径为 10~100 千米、持续时间为 2~10 个月的涡旋。相比于海洋中肉眼可见的涡旋,中尺度涡有着更大的半径以

及更长的持续时间,但是其规模远小于海洋中的持续存在的大环流。中尺度涡携带极大的动能,涡旋内海水运动速度非常快,相对洋流平均流速而言,要快几

收稿日期: yyyy-mm-dd **Date 六号** 修回日期: yyyy-mm-dd **Date 六号**

项目: 如有国家或省部级基金资助,请写上正确基金项目名称和编号

倍到一个量级。径向涡旋涉及几十米到上百米，甚至上千米的深海，海洋深层的营养盐和冷水会被径向涡旋带到海洋表面。中尺度涡还能够将海表暖水压到较深的海洋中，在全球海洋物质、能量和热量等的运输和分配中起着不可忽视的作用。因此，海洋涡旋的研究具有非常重要的科学意义和渔业、军事价值。

近年来，深度神经网络在图像分类、人脸识别、文本识别等方面取得了非凡的成就，特别是在图像分类领域，一些新型的技术比如随机丢弃技术、正则化、批归一化等，使得深度卷积神经网络模型在复杂的计算机视觉问题中展现出高效的性能。而在目标检测和分割领域，深度网络模型(R-CNN, Faster R-CNN, Mask R-CNN 等)的很多改进版本，识别准确率达到了很高的水准，应用到了生产生活的很多领域。

在卫星资料、浮标资料和高分辨模式的辅助下，中尺度涡检测已成为物理海洋领域的研究热点。但从卫星遥感数据中识别中尺度涡的主要方法还是依赖专家分析，这种方法劳动强度大，很难满足快速、准确检测的需求，对于现在的数据量而言更难以做到全面的检测和分析。另外，很多算法利用海表高度、温度等数据，基于流场几何特征、边缘检测以及拉格朗日随机模型进行中尺度涡检测，这些算法误检率较高。还有一些基于图像和深度神经网络的方法，将海洋卫星遥感数据转换成图像作为网络输入，这一类方法往往会损失卫星遥感数据的细节信息，且已有的深度学习模型相对简单，因此检测结果也不够精确。

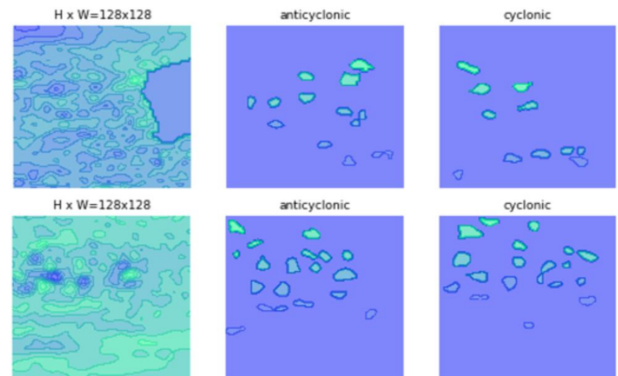
为解决上述问题，我们将探索使用人工智能领域中的深度学习方法，对涡旋进行检测和分析，也就是利用深度卷积网络和多模态海洋卫星遥感数据，实现对中尺度涡的准确检测。我们将使用多模态数据融合，对卫星遥感数据，如海洋表面高度、温度及流速数据进行融合学习，摒弃以往将单一类型数据转换成图像数据再进行检测分析的策略。同时，借鉴经典的目标检测、语义分割网络的优点，设计区域提取网络的用于中尺度涡检测。其中，残差网络部分学习中尺度涡特征表示，区域生成网络生成含有中尺度涡的区域并提取特征，头网络部分负责中尺度涡类别和范围预测，网络能够通过端到端的方式进行学习。

本文主要从设计应用于中尺度涡检测的深度神经网络入手，探索神经网络在提取卫星遥感数据特征中的有效性。本文通过建立特定中尺度涡检测数据集，训练深度神经网络模型，并对比本文提出的基于深度神经网络的方法和其同类方法之间的有效性以及优缺点。

## 1. 数据集来源及构造

### 1.1 数据集来源

本研究使用的卫星遥感数据来自于哥白尼海洋环境监测服务中心。哥白尼海洋环境监测服务中心的全球海洋物理再分析数据包(GLOBAL OCEAN PHYSICS REANALYSIS GLORYS2V4)包含海表温度，盐度，洋流，高度以及海冰参数的日常平均值，分辨率为 0.25 度，覆盖时间为 1993 年~2015 年。由于其精度高，数据类型全面，所以本数据集的建立使用了全球海洋物理再分析数据包中能够辅助中尺度涡检测的温度、高度以及流速数据。其中海水流速数据包含 2 个方向，分别是东向海水的流速以及北向海水的流速。



本文实验的数据是 GLORYS2V4 中 2000 年 01 月 16 日到 2009 年 12 月 16 日共计十年的温度、高度以及流速数据，其中这三种数据的维度分别为  $681 \times 1440 \times 120$ ，681 为纬度的维度，1440 为经度的维度，120 表示数据来自连续的 120 个月。为了保证神经网络的训练速度，本研究使用了区域大小为  $128 \times 128$  的遥感数据。数据采集的方式为随机不重复的在每个月的各类数据中取 13 次，并保证温度、高度以及流速的对应位置相同。

在标签(label)的设计中，气旋涡标(cyclonic)标注为 1.0，反气旋涡(anticyclonic)标注为 -1.0，没有涡的区域标注为 0.0。这样能将三种情况的差异尽可能地变大，在识别的时候尽可能降低学习的难度。

在训练集和测试集分配上选择按照 3: 7 的比例将所有数据分为测试数据和训练数据。

### 1.2 中尺度涡蒙版的生成

本文使用的 Mask-RCNN 算法除了需要给出涡形类别的标注外，还需要给出对应区域的中尺度涡的蒙版(Mask)作为网络的评价，而数据集中并没有直接的给出中尺度涡的蒙版，我们需要基于一个传统的非机器学习算法 EddyScan 对卫星雷达高度计数据进行

中尺度涡检测,并将此结果作为数据的蒙版标注,然后对本文提出的算法进行有效性检测。

该方法在-100cm 到+100cm 的区间进行 1cm 间隔的重复计算。在每个阈值  $i$ ,作者识别出数量具有至少为  $i$  的海平面高度异常的所有连通组件。然后,算法去除属于所识别的连通分量的所有像素,并且以  $i$  递增。为了识别反气旋涡,作者在-100cm 初始化并以 1cm 步长增加到+100cm。相反,通过将  $i$  从+100cm 减小到-100cm 来实现对气旋涡的检测。

对于大于正常规模的涡旋,用凸包函数(convex hull function)来确定包含涡旋的所有网格数据的最小凸集的大小。如果凸包的面积远大于连接区域的面积,则可能是多个涡旋合并的情况,并且连接的部分未标记为涡旋,丢弃连接的区域,它将保留在稍后要检查的网格数据中,增加了再次检测的几率,这样能够保证不漏检,运行流程见**算法 1**。

#### 算法 1: 自动全局涡旋追踪算法—EddyScan

输入: 海洋表面高度数据 (SSH)。

输出: E: 全局涡旋列表, 涵盖全局内每个网格数据所属涡旋;

A: 每个涡流的振幅;

S: 每个涡流的表面积。

对于每个时间步  $t_i$ :

对于每个阈值  $tr_i \in \{-100:100\}$ :

如果  $i$  处 SSH 的值  $i(p_i) < tr_i$ :

$p_i = 0$ ;

否则:

$p_i = 1$ ;

检查所有剩余的连接区域;

对于每个连接区域  $CC_i$ :

如果  $CC_i$  符合上文所述标准:

将所有  $p_j \in CC_i$  标注为涡旋;

将  $p_j$  从数据中移除;

退出循环;

退出循环;

退出循环。

该算法运行结束后,我们可以得到 SSH 数据对应该图的气旋涡和反气旋涡的蒙版,及其旋涡的个数,我们为了保证算法能够有效的检测中尺度涡,我们剔除了不含涡旋的数据,保证了我们的训练集和验证集都是存在中尺度涡。

## 2 多模态数据融合和深度区域提取网络的算法描述

卫星遥感数据中的海洋表面温度、高度以及流速都会从不同的角度描述中尺度涡的特征,所以理想的情况下,使用尽可能多的数据类型进行中尺度涡检测是最有效的。多模态数据的融合不仅有利于卷积网络进行中尺度涡特征的提取,更有利于进行中尺度涡的预测。

### 2.1 数据的预处理

首先,不同数据的数值差异很大,在神经网络的

前向传播中,会造成前向传播过程中的数据计算异常。其次,近似为 0 的数值频繁在很多数据中出现,会造成预测结果难以学习。最后,不同类型的数据对中尺度涡检测起到的作用是不同的,换句话说,数据需要按比重进行缩放。

我们采用数据预处理进行数据整合。在数据预处理过程中,最重要的是解决数据分布不均匀的问题,本研究尝试使用归一化方式是 min-max 标准化[60] (Min-max normalization),这种方式是通过线性计算,把原始的遥感数据进行线性缩放,最终落到[a, b]之间。首先需要找到原始数据分布中的最大值(max)和最小值(min),然后计算缩放系数,


$$k = \frac{b-a}{\max - \min}$$

这里我们一般将区间设置为[0, 1],因此计算方式也很简单:

$$x^* = \frac{x - \min}{\max - \min}$$

### 2.2 多模态数据融合

在本文使用的海洋数据中,一共有 3 种,分别海



洋表面高度数据,海洋表面温度数据,海洋表面流速数据(双通道),.

通过一个简单的卷积神经网络,我们将包含多模态信息的数据进行特征融合。

$$x^* = (|H, T, V| \times x_1 + b_1) \times x_2 + b_2$$

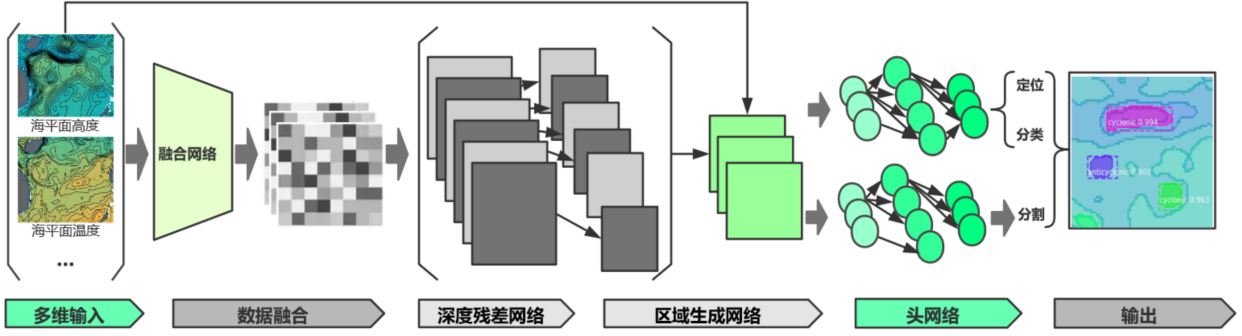
H 表示海洋表面高度数据, T 表示海洋表面温度数据, V 表示海洋表面流速数据

融合后得到的数据 $x^*$ 作为第二步深度区域提取网络的输入。

### 2.3 深度区域提取网络


本文用的到目标检测算法是深度学习中具有分类、定位和实例分割功能的 Mask-RCNN 算法。其主要由 4 个部分组成:深度残差网络 resnet101,区域生成

网络 PRN,用于定位和分类的全连接网络,生成实例分割的反卷积网。



### 2.3.1 特征提取网络


本文中针对中尺度涡的检测问题难度相比较于复杂场景目标检测任务来说,难度较低,所以我们选择了在 coco 数据集下预训练好的 ResNet101 作为特征提取网络.由于我们在 ResNet101 使用了残差连接,可以有效地减少网络的过拟合,同时减少梯度在反向传播的时候产生梯度弥散现象.



上一步得到的多模态融合数据,经过深度残差网络得到一张通道数维 256 维,尺度为 8\*8 的特征图 (feature maps),这个特征图表示的是多模态融合数据的高维特征.

### 2.3.2 区域生成网络 RPN

PRN(Region Proposal Networks)网络的作用是找出多模态数据中可能存在旋涡的位置(proposals).



产生 proposals 需要用到  $3 \times 3$  的滑动窗口(slides window),每一个滑动窗口需要产生 9 个锚点框 (anchors box),每一个锚点窗口由 5 个变量组成,分别是:  $x, y, w, h, p, \hat{p}$ , 表示的是对应原始输入数据中可能存在涡旋的位置的坐标以及以该坐标为几何中心的宽'为  $w$ ,高为  $h$  的锚点窗口, $p$  表示该锚点窗口为旋涡的概率,  $\hat{p}$  表示不是旋涡的概率.

$$L_{cls}(p_i, \hat{p}_i) = -\log[\hat{p}_i p_i + (1 - \hat{p}_i)(1 - p_i)]$$

接下来通过比较 anchor box 和 ground truth 的 IOU 是否大于置信度 求得  $P^*$ ,对预测为旋涡的 anchor box 的  $x, y, w, h$  做回归.

回归的公式为:

$$t_x = \frac{(x - x_a)}{W_a} t_y = \frac{(y - y_a)}{h_a}$$

$$t_w = \log(W / W_a) t_h = \log(h / h_a)$$


$$t_x^* = \frac{(x^* - x_a)}{W_a} t_y^* = \frac{(y^* - y_a)}{h_a}$$

$$t_w^* = \log(W^* / W_a) t_h^* = \log(h^* - h_a)$$

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{reg}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i L_{cls} p_i^* L_{reg}(t_i, t_i^*)$$

上式中,  $d(\cdot)$ 表示两点之间的距离,  $\Delta h$  和  $\Delta w$  表示  $x$  与  $x^*(r, j)$  横纵坐标的差值, 作为双线性插值的系数与原始梯度相乘.

运用训练好的 RPN 网络,我们在 feature maps 上预测出旋涡可能出现的区域 proposals, 将这些可能出现中尺度涡的区域作为接下来全连接网络的输入. 由于全连接网络需要固定的输入,所以我们使用 ROIAlign 方法规整到相同的尺寸.



ROI Align 基于双线性插值的方法, 利用 feature map 上距离采样点最近的四个像素得到其像素值. 整个过程中没有对 ROI, 均分 ROI 产生的子区域(bins)和采样点进行量化.

其前向传播公式为



$$f(x, y) \approx \frac{f(Q_{11})}{(x_2 - x_1)(y_2 - y_1)}(x_2 - x)(y_2 - y) + \frac{f(Q_{21})}{(x_2 - x_1)(y_2 - y_1)}(x - x_1)(y_2 - y) \\ + \frac{f(Q_{12})}{(x_2 - x_1)(y_2 - y_1)}(x_2 - x)(y - y_1) + \frac{f(Q_{22})}{(x_2 - x_1)(y_2 - y_1)}(x - x_1)(y - y_1)$$


其反向传播公式为:

$$\frac{\partial L}{\partial x_i} = \sum_r \sum_j [d(i, i^*(r, j)) < 1] (1 - \Delta h)(1 - \Delta w) \frac{\partial L}{\partial y_{rj}}$$

利用 ROIALign 采样方法,我们很大程度上解决了传统池化方法中像素点精度造成的 Misalignment 对齐问题。

### 2.3.3 定位、分类和实例分割

接下来我们将规整后的 proposals 拉伸成一维向量,作为第一个全连接网络的输入,这个全连接网络的输出分为三个部分。



第一部分负责判断中尺度涡的类别.上一步中的 RPN 网络已经帮我们检测出来改 proposal 区域内存在旋涡,这一部分的全连接网络的输出是一个仍然是一个二维的向量,每一位分别表示气旋涡和反气旋涡的概率.其损失函数  $L_{cls}$  的计算公式为:

$$L_{cls}(p_i, p_i^*) = -\log[p_i^* p_i + (1 - p_i^*)(1 - p_i)]$$

第二部分为预测中尺度涡的位置,其损失函数  $L_{box}$  表示预测的旋涡所在的位置,其计算公式为为:

$$L_{box} = \sum_i^n g(t_i^u - v_i)$$

其中,  $t_u$  表示真实分类对应的预测参数  $t_u$ ,  $v$  表示真实的平移缩放参数,  $n=4$ , 表示一个目标选框的四个数值表示。 $g$  表示 Smooth L1 损失,在区间 $[-1,1]$ 内为二次函数,其余区间为线性函数。Smooth L1 损失的优势在于能够让模型更加鲁棒,在训练过程中不容易造成过大的梯度值,避免越过最优值的情况出现

$$g(x) = \begin{cases} 0.5x^2 & x < 1 \\ |x| - 0.5 & \text{others} \end{cases}$$

第三部分为掩码分支,其作用在于对目标区域的中尺度涡进行实例分割.将 proposal 通过反卷积转化为和 ground Truth 尺度一致的 bounding box.如果 ground truth 中标记了这个 bounding box 中是气旋涡的话,那我们就只针对气旋涡的 mask 进行分割,而对这个 bounding box 中其他可能存在的物体一律忽视.通过逐像素计算其平均二值交叉熵得到其损失函数为:

$$L_{mask}(Cls\_k) = \text{Sigmoid}(Cls\_k)$$

通过上面三个损失函数,我们求得了多模态数据中的存在的中尺度涡的定位,类别以及实例分割

## 3 实验结果与分析

### 3.1 深度学习框架与预训练模型的选取

本文选择了深度学习框架为 Keras 以及 TensorFlow, Keras 是一个高级的神经网络 API(application programming interface, 应用程序编程接口), Keras 对 Tensorflow、Theano 等框架都有良好的兼容性。Keras 的设计初衷是速度快,封装性强,且能够实现功能复杂的深度神经网络模型。TensorFlow 是目前使用范围最广的深度学习框架,由谷歌的人工智能团队谷歌大脑(Google Brain)负责开发和维护。

硬件方面,深度模型的训练需要进行大量的并行计算,为了在更短的时间内对模型进行高效的学习,我们使用了英伟达(NVIDIA)的中高端并行计算产品:GeForce GTX 1080Ti,并使用双显卡来提高设备的并行计算能力。

在预训练模型选择上,本研究使用了 Microsoft COCO 数据集对主题网络进行了预训练。Microsoft COCO 数据集是一个用于视觉算法训练的大型数据集,内含有超过 30 万张标注图像,超过 200 万个标注实体,主要用于目标检测,语义场景分割等模型的训练,标注复杂程度上远超图像分类。

### 3.2 评价指标的设立

本研究通过计算模型 mAP 检验模型的准确度。mAP 为不同 IOU(intersection over union)阈值下的平均准确率(average precision)的平均值。IOU 指的是检测结果和真实标注的交集与并集的比值,IOU 值越大说明检测结果越好,如图所示。本研究中 IOU 阈值取 0.50 至 0.95 之间间隔为 0.05 的所有值。

### 3.3 实验结果分析

本节将从三个方面设计实验, 首先选出适合中尺度涡检测网络的最佳超参数, 如学习率、锚点尺度, 然后测试多模态数据融合的最佳方法, 最后和同类型深度学习算法比较中尺度涡检测准确度。

#### 3.3.1 模型超参数选择

本研究采用的优化方法为随机梯度下降(stochastic gradient descent, SGD), 超参数包括学习率(learning rate)、锚点规模(anchor scale)等。随机梯度下降是目前比较优秀的深度学习模型优化算法, 相比于梯度下降来说, 能够避免陷入局部最优值, 但在速度上要略逊于 Adam[73]、RMSProp[74]算法, 但是随机梯度下降训练的模型准确率往往表现最出色。学习率表示模型参数的更新幅度, 过大的学习率将会导致更新幅度过大可能越过最优值点, 过小的学习率将导致更新幅度偏小学习时间过长。学习率衰减是指, 模型在学习过程中设计一定规则让学习率按规则缩小, 这样就能在接近最优值点时防止因为更新幅度过大而偏离最优值点。锚点规模表示滑动窗口生成区域的尺寸比例。

锚点规模	学习率 (头网络)	学习率 (整体训练)	mAP (%)
(8,32,128)	0.001	0.001	45.50
(4,16,64)	0.001	0.001	53.89
(8,32,128)	0.001	0.0001	52.62
<b>(4,16,64)</b>	<b>0.001</b>	<b>0.0001</b>	<b>56.35</b>

由上述检测结果可得, 在锚点规模为(4,16,64), 训练头网络的初始学习率为 0.001, 整体训练的初始学习率为 0.0001 时, mAP 最高为 56.35。

#### 3.3.2 多模态数据融合实验

本小节设置的实验旨在测试多模态数据融合方法的有效性。在 3.2 节中, 我们介绍了会对每个类型的数据进行了归一化处理, 并对每个数据类型赋予权重,  $\alpha$ 、 $\beta$ 、 $\gamma$  分别是海洋表面温度、高度以及流速的权重超参数, 且  $\alpha + \beta + \gamma = 1$ 。权重超参的设定不仅能够在一定程度上体现出不同数据类型在进行中尺度涡检测过程中的重要性, 而且能够探索多模态数据融合是否对中尺度涡的检测有帮助。

我们固定其他参数, 尝试不同的  $\alpha$ 、 $\beta$ 、 $\gamma$  组合进行实验, 训练方式与 3.3.1 小节相同, 得到的实验结果

$\alpha$ 、 $\beta$ 、 $\gamma$ 比例	mAP	$\alpha$ 、 $\beta$ 、 $\gamma$ 比例	mAP
1:1:1	60.48	3:5:2	60.15
2:2:1	58.69	2:3:5	57.75
2:1:2	58.70	3:2:5	55.76
1:2:2	57.43	1:1:0	57.43
2:1:1	66.85	1:0:1	56.48
1:2:1	59.62	0:1:1	52.91
1:1:2	58.49	1:0:0	56.35
<b>5:3:2</b>	<b>70.27</b>	0:1:0	44.91
5:2:3	67.47	0:0:1	49.26
2:5:3	59.73		

通过上述实验结果可知, 当  $\alpha$ 、 $\beta$ 、 $\gamma$  的比例为 5:3:2 时, 实验结果最优。

#### 3.3.3 同类算法对比

本节将对比实现涡旋检测的深度学习方法, 由于目前提出使用深度神经网络进行中尺度涡检测的算法并不多, 所以, 本文选了效果比较优秀的两个方法

	DeepEddy	EddyNet	本方法
涡旋分类	✓	✓	✓
位置预测	×	×	✓
涡旋分割	×	✓	✓
图像处理	✓	✓	✓
遥感数据处理	×	×	✓

进行对比: 方法一是 DeepEddy; 方法二是 EddyNet。

功能实现方面, DeepEddy 仅能实现涡旋图片分类, 而 EddyNet 在图片分类的基础上实现了涡旋的分割, 本方法能基于图片和遥感数据实现涡旋分类、分割以及位置预测。

方法	mAP
EddyNet	52.16
<b>本方法 (基于多模态融合数据)</b>	<b>70.27</b>

本研究提出的方法在使用多模态融合数据进行训练时检测结果好于 EddyNet。

## 4 结束语

本文将中尺度涡检测和深度学习相结合, 探索了深度学习中目标检测算法在海洋遥感数据处理上的能力, 并能够对遥感数据进行较高准确率的涡旋分割。

本研究主要贡献如下:

1) 提出了基于深度区域提取网络的涡旋检测模型。在功能方面, 实现了卫星遥感数据上的涡旋分割, 包含了分类, 精细定位。另外, 模型本身也具有一定的创新性, 针对涡旋检测的复杂程度对模型的深度进行设计。

2) 为了验证涡旋检测模型的有效性, 本研究提出了涡旋检测数据集。数据集制作采用了传统非深度学习方法, 对遥感数据中每个数据点的类别进行了精准标注; 然后在大型数据集 ImageNet 上进行预训练, 并在涡旋检测数据集上进行训练, 得到了优秀的检测精度。

3) 本研究使用了多模态数据融合。在涡旋检测的

过程中使用到了海洋表面高度、海洋表面温度,以及海水流速数据。经过对比实验表明,融合数据在涡旋检测问题上要优于单一类型的数据,并且通过实验找到了数据融合的最佳策略。

## 参考文献


- [1] 董昌明, 蒋星亮, 徐广珺. 海洋涡旋自动探测几何方法、涡旋数据库及其应用 [J]. 海洋科学进展, 2017, 35(4): 439-53.
- [2] 李燕初, 蔡文理, 李立. 南海东北部海域中尺度涡的季节和年际变化 [J]. 热带海洋学报, 2003, 22(3): 61-70.
- [3] 南海中尺度涡的时空变化规律 I. 统计特征分析 [J]. 海洋学报, 2007, 29(3): 14-22.
- [4] 王桂华. 南海中尺度涡的运动规律探讨 [D]; 中国海洋大学, 2004.
- [5] 南海中尺度涡研究进展 [J]. 地球科学进展, 2005, 20(8): 882-6.
- [6] JIWEN L, YAP-PENG T, GANG W. Discriminative multimanifold analysis for face recognition from a single training sample per person [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2013, 35(1): 39-51.
- [7] SIMO-SERRA E, TRULLS E, FERRAZ L, et al. Discriminative Learning of Deep Convolutional Feature Point Descriptors; proceedings of the IEEE International Conference on Computer Vision, F, 2016 [C].
- [8] SCHROFF F, KALENICHENKO D, PHILBIN J. FaceNet: A Unified Embedding for Face Recognition and Clustering [J]. 2015,
- [9] WEN Y, ZHANG K, LI Z, et al. A Discriminative Feature Learning Approach for Deep Face Recognition [M]. 2016.
- [10] CONTE A, CARPENTER B, CASE C, et al. Text Detection and Character Recognition in Scene Images with Unsupervised Feature Learning; proceedings of the International Conference on Document Analysis & Recognition, F, 2011 [C].
- [11] KARATZAS D, GOMEZ-BIGORDA L, NICOLAOU A, et al. ICDAR 2015 competition on Robust Reading; proceedings of the International Conference on Document Analysis & Recognition, F, 2015 [C].
- [12] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple

way to prevent neural networks from overfitting [J]. Journal of Machine Learning Research, 2014, 15(1): 1929-58.

## 作者介绍:



**陈扬, 学士, 2017 年中国海大学大学信息科学与技术学院计算机科学与技术专业在读学士, 主要研究方向为深度学习**



**杨琛, 硕士, 2019 年获中国海洋大学大学海洋与大气学院海洋科学专业学士, 同年保送至中国海洋大学大学海洋与大气学院攻读硕士研究生, 主要研究方向为高性能计算。**



**刘博文, 学士, 2016 年中国海大学大学海洋与大气学院海洋科学专业在读学士, 主要研究方向为高性能计算。**